

Interaktive Finanzanalyse mit Machine Learning

Fünfsseitige Projektausarbeitung · Version 1.0 · QUA³CK-Prozessmodell

Leitfrage

Wie können historische US-Aktienmarktdaten genutzt werden, um eine interaktive Finanzanalyse-App zu entwickeln, die technische Analyse, ML-Signalgebung und risikobasierte Positionsplanung nachvollziehbar kombiniert?

Kurzfassung

WealthScope AI ist ein wissenschaftlicher Streamlit-Prototyp. Er verbindet 192.119 Feature-Datenpunkte aus 26 US-Blue-Chip-Titeln (1962–2017) mit technischen Indikatoren, einem reproduzierbaren Klassifikationsbenchmark und erklärbaren Risiko- und Transfermodulen. Ziel ist nicht die Behauptung sicherer Kursprognosen, sondern eine transparente Demonstration dessen, was Machine Learning aus historischen Kursdaten lernen kann – und wo seine Grenzen liegen.

Beitrag und Abgrenzung

- QUA³CK dokumentiert den Weg von der Frage bis zum Wissenstransfer.
- Fünf Modellgenerationen werden auf demselben zeitlichen Testfenster verglichen.
- StandardScaler und Imputation werden ausschließlich innerhalb der Trainingspipeline gefittet.
- Das schwache Ergebnis wird nicht behauptet, sondern gegen die naheliegenden Gegenerklärungen geprüft: Ein naiver Zufalls-Split würde dieselben Daten mit AUC 0,581 statt 0,519 bewerten – ein 4,2-mal größeres scheinbares Signal.
- Die App erklärt Ergebnisse, bietet Export und Lernstudio, ist aber weder Handelsbot noch Anlageberatung.

Autor: Soufiane Fedan · Matrikelnummer 10247259 · Tutor: Klaus Quibeldey-Cirkel · Modul Data Analytics und Big Data

Q · U · A

Problem, Datenverständnis und Features

1. Problemstellung und Hypothesen

Privatanleger treffen auf Datenfülle, widersprüchliche Signale und schwer erklärbare KI. WealthScope AI übersetzt Marktdaten in prüfbare Analysen. H1 untersucht, ob der Random Forest die Zufallsgrenze ROC-AUC 0,5 robust übertrifft. H2 prüft den verständlichen Wissenstransfer über Streamlit. H3 bewertet den praktischen Mehrwert der Kombination aus Technik, ML und Risiko.

2. Datenbasis und Datenqualität

Aspekt	Umsetzung	Bedeutung
Quelle	Kaggle US Stocks & ETFs, CCO	Nachvollziehbare historische Basis
Umfang	192.119 Zeilen, 26 Ticker	Mehrere Sektoren und Marktphasen
Zeitraum	1962–2017	Lange Historie, aber Distribution Shift zu heute
Ziel	target_20d	Kurs in 20 Handelstagen höher: 1, sonst 0
Fehlwerte	Median-Imputation in Pipeline	Robust gegen Ausreißer; kein Testwissen

3. Feature Engineering

- Rendite: daily_return, return_5d und return_20d.
- Trend: relative Abstände zu MA-20, MA-50 und MA-200.
- Risiko: volatility_20d und drawdown zum bisherigen Hoch.
- Alle Features verwenden nur Informationen, die zum Beobachtungszeitpunkt vorliegen.

StandardScaler – zentraler methodischer Punkt

$z = (x - \mu_{\text{Train}}) / \sigma_{\text{Train}}$. Der Scaler lernt Mittelwert und Streuung nur aus X_{train} und transformiert X_{test} mit denselben Parametern. Das ist für Logistische Regression und Linear-SVM wichtig, weil deren Optimierung bzw. Abstände von der Merkmals-Skala abhängen. Entscheidungsbäume und Random Forests sind weitgehend skaleninvariant; dort ist der Scaler nicht erforderlich.

A · A

Algorithmus, Adaption und faire Validierung

4. KI damals und heute: Modellvergleich

Der Benchmark zeigt die historische Entwicklung der Klassifikation: von einer einfachen Mehrheitsregel über lineare und regelbasierte Verfahren bis zum Ensemble. Alle Kandidaten erhalten dieselben Features und dieselben Trainings- und Testzeiträume.

Epoche	Modell	Grundidee	Scaler	AUC
Baseline	Dummy (Mehrheitsklasse)	Kontrollmodell	nicht nötig	0,500
1958	Logistische Regression	Statistisch-linear	ja	0,517
1984	Entscheidungsbaum	Regelbasiert / White Box	nicht nötig	0,518
1995	Linear SVM	Maximum Margin	ja	0,517
2001	Random Forest	Ensemble Learning	nicht nötig	0,519

Tabelle 1: Fünf Modellgenerationen auf identischem purged Out-of-Time-Fenster. Quelle: scripts/train_and_diagnose.py.

5. Leakage-sichere Pipeline

Trainingsfolge

Zeitlich sortieren → jüngste 20 % als unangetasteten Out-of-Time-Test reservieren → 20 Handelstage Purge vor jedem Validierungsfenster → Median-Imputer auf Training fitten → StandardScaler nur bei linearen Modellen auf Training fitten → Modell fitten → Test einmalig auswerten.

6. Warum kein zufälliger Split? Eine Messung

Die Zielvariable blickt 20 Handelstage voraus. Bei einem Random Split gelangen spätere Marktregime und überlappende Zielhorizonte in das Training. Wie groß dieser Effekt ist, bleibt in vielen Arbeiten unbeziffert – hier wurde er gemessen: dasselbe Modell, dieselben Daten, nur die Aufteilung variiert.

Aufteilung	Leakage	ROC-AUC	Accuracy
zeitlich + 20 Handelstage Purge (v1.0)	keine	0,5192	0,5187 (Baseline 0,591)
zeitlich, ohne Purge	überlappende Zielhorizonte	0,5240	0,5308 (Baseline 0,591)
naiver Zufalls-Split 80/20	Zukunft im Training + Zielhorizont-Overlap	0,5813	0,5467 (Baseline 0,559)

Tabelle 2: Random Forest mit identischer Konfiguration. Gemessen am Zufallsniveau 0,5 erscheint das Signal beim naiven Zufalls-Split mit 0,081 statt 0,019 – also 4,2-mal größer, ohne dass sich Modell oder Daten ändern. Quelle: scripts/validation_experiments.py.

Die niedrige Kennzahl dieser Arbeit ist damit kein Qualitätsmangel, sondern die Folge einer Validierung, die dem Modell die Zukunft entzieht. Vier expanding Walk-forward-Folds prüfen zusätzlich die Stabilität über frühere Zeitfenster.

Random-Forest-Konfiguration: 200 Bäume, max_depth=8, min_samples_leaf=5, class_weight='balanced', random_state=42.

C · EVALUATION

Ergebnisse, Interpretation und Grenzen

Modell	ROC-AUC	Balanced Accuracy	Walk-forward AUC
Dummy (Mehrheitsklasse)	0,500	0,500	0,500
Logistische Regression	0,517	0,504	0,491
Entscheidungsbaum	0,518	0,513	0,515
Linear SVM	0,517	0,504	0,491
Random Forest	0,519	0,513	0,514

Tabelle 3: Identisches Out-of-Time-Testfenster; Zufallsniveau der ROC-AUC = 0,5. Quelle: eigene Berechnung mit scripts/train_and_diagnose.py.

Kennzahl	Random Forest	Einordnung
Accuracy	0,519	unter Mehrheitsbaseline 0,591
Balanced Accuracy	0,513	nur knapp über Zufall
ROC-AUC	0,519	schwaches Ranking-Signal
Walk-forward AUC	0,514	über Zeit nicht stabil stark

7. Bewertung der Hypothesen

- H1 falsifiziert, nicht ungeprüft: AUC 0,519 liegt über 0,5, der Abstand ist jedoch klein und zeitlich instabil. Die Hypothese war so formuliert, dass sie scheitern konnte – genau das macht sie prüfbar.
- H2 im Prototyp umgesetzt: Methodik, Kennzahlen, Export und Lernstudio sind zugänglich; eine formale Nutzerstudie steht aus.
- H3 teilweise plausibel: Die Kombination verbessert Orientierung und Risikokommunikation, beweist aber keinen wirtschaftlichen Mehrwert.

Zwei Gegenerklärungen wurden ausgeschlossen

Modellkapazität: Über sieben Regularisierungsstufen von unbeschränkt (Trainings-AUC 1,000) bis stark gestutzt (0,543) bewegt sich der Test-AUC nur um 0,0071 (0,5121 bis 0,5192); die beste Einstellung ist max_depth=8, leaf=5 (v1.0). Die Trainings-Test-Lücke entsteht also ausschließlich auf der Trainingsseite – das Modell überanpasst Rauschen. Datenmenge: Über die 2,3-fache Trainingsmenge verändert sich der Validierungs-Score der Lernkurve nur um -0,005 und bleibt nahe Zufallsniveau. Weder mehr Kapazität noch mehr Daten heben das Signal.

8. Fachliche Grenzen

Historische Kurse enthalten wenig dauerhaftes Vorhersagesignal. Selektions- und Survivorship-Effekte, Transaktionskosten, Slippage, Steuern und Portfoliozwänge sind nicht modelliert. Live-Daten nach 2017 stellen einen Distribution Shift dar. Feature Importance und SHAP erklären statistische Zusammenhänge, aber keine Kausalität. Die ehrliche geringe Leistung ist deshalb das zentrale wissenschaftliche Ergebnis.

K · KNOWLEDGE

Wissenstransfer, Kursbezug und Fazit

9. Umsetzung in der Anwendung

Baustein	Funktion
Marktanalyse	Kurs, Moving Averages, Candlesticks, Volatilität und Drawdown
ML Insights	Modellvergleich, Konfusionsmatrix, ROC/PR, Lernkurve, Wichtigkeiten
Kapital-Kompass	Risikobasierte Positionsgröße mit transparenten Annahmen
Portfolio-Simulator	Szenarien statt Renditeversprechen
Lernstudio	Quiz, direktes Feedback und arsnova.eu-kompatibler Export
Methodik & Export	QUA ³ CK, Model Card und reproduzierbare Dateien

Zugang zur Anwendung

Quellcode und vollständige Anwendung: <https://github.com/fedansoufiane-commits/forexscope-ai>

Lokal starten (Python 3.11 oder neuer): 1) git clone <https://github.com/fedansoufiane-commits/forexscope-ai> 2) cd forexscope-ai 3) pip install -r requirements.txt 4) streamlit run app.py

Schritt 2 nicht überspringen: ohne den Wechsel ins Projektverzeichnis startet Schritt 4 eine fremde app.py oder bricht ab. Kontrolle: ls app.py src/models/ muss alle drei auflisten.

Die App öffnet sich anschließend unter <http://localhost:8501>. Die Diagnostik-Artefakte sind versioniert im Repository enthalten, ein Neutraining ist für den Start nicht erforderlich.

Kennzahlen reproduzieren: python scripts/train_and_diagnose.py (Benchmark) und python scripts/validation_experiments.py (Tabelle 2 sowie der Kapazitäts-Sweep).

10. Bezug zur Vorlesung

Die Ausarbeitung verbindet ML-Grundlagen und historische Modellgenerationen mit Klassifikationsmetriken, Lernkurven, SVM, Entscheidungsbäumen und Random Forests. Der StandardScaler macht dabei sichtbar, dass Vorverarbeitung kein Nebenschritt ist: Sie beeinflusst lineare und abstandsorientierte Verfahren und muss innerhalb der Pipeline liegen. QUA³CK strukturiert die technische Arbeit und verhindert, dass das Modell vor Datenverständnis und Fragestellung steht.

11. Fazit

Kernaussage

WealthScope AI 1.0 ist kein Kursorakel, sondern ein transparenter ML-Lern- und Analyseprototyp. Das Ergebnis der Arbeit ist nicht das Modell, sondern eine Messung: Wie viel verwertbare Information tragen rein kursbasierte technische Indikatoren? Antwort – nahezu keine, belegt an 190.527 Beobachtungen mit elf Jahren unangetastetem Testzeitraum und gegen zwei ausgeschlossene Gegenerklärungen. Das ist eine nachgerechnete, nicht bloß zitierte Bestätigung der Effizienzmarkthypothese. Der Mehrwert liegt in reproduzierbarer Methodik, fairem Modellvergleich und klarer Risikokommunikation. Der nächste wissenschaftliche Schritt ist ein Forward-Test mit Transaktionskosten, exogenen Variablen und formaler Nutzerstudie.

Quellen (Auswahl)

Fama, E. (1970): Efficient Capital Markets. Journal of Finance 25(2). · Géron, A. (2023): Praxiseinstieg Machine Learning, 3. Aufl. · Lundberg, S.; Lee, S.-I. (2017): A Unified Approach to Interpreting Model Predictions. NeurIPS. · Pedregosa, F. et al. (2011): Scikit-learn. JMLR 12. · Stock, A. et al. (2021): QUA³CK – A Machine Learning Development Process. · Marjanovic, B.: Huge Stock Market Dataset, Kaggle, CC0.