





WealthScope AI

ML-gestützte Finanzanalyse · QUA³CK-Prozessmodell



Data Analytics und Big Data (DSDABD072501) · Tutor: Klaus Quibeldey-Cirkel · Soufiane Fedan · Matrikelnr. 10247259

Leitfrage: Wie lassen sich historische US-Aktienmarktdaten nutzen, um mit Machine Learning eine interaktive Finanzanalyse-App zu bauen, die technische Analyse, ML-Signal und Risikoplanung nachvollziehbar verbindet — und ehrlich über ihre Grenzen ist?

DER WISSENSCHAFTLICHE FAHRPLAN



KERNANALYSEN (ML-INSIGHTS)



Warum 51,9 % das ehrliche Ergebnis ist. Der Test ist zeitlich unangetastet: Training bis 2006, Prüfung auf 2006–2017, dazwischen 20 Handelstage Sperrzone. So bleibt die Accuracy unter der Mehrheitsbaseline von 59,1 % und der ROC-AUC bei 0,519 — H1 ist damit falsifiziert, nicht ungeprüft. Genau das erwartet die Effizienzmarkthypothese (Fama 1970). Ein naiver Zufalls-Split bewertet dieselben Daten mit 0,581: ein 4,2-mal größeres scheinbares Signal.

Methodik

RandomForest (Median-Imputer → RF; StandardScaler nur bei LogReg und Linear SVM, Bäume sind skaleninvariant). Purged Out-of-Time-Test plus 4 expandierende Walk-forward-Folds, alles nur im Trainingsfenster gefittet. 8 Features aus OHLCV, Ziel target_20d.

Grenzen (ehrlich benannt)

- Keine exogenen Faktoren (Makro, Geopolitik)
- Kein Sentiment im Modell
- Statisches Modell ohne Nachtraining
- Historie garantiert keine Zukunft

QUELLEN (KURZ)

Géron (2023), Praxiseinstieg ML (Kurslehrbuch, Kap. 1–9) · Fama (1970), Efficient Capital Markets · Lundberg & Lee (2017), SHAP · Li et al. (2024), Imputation · Pinheiro et al. (2025), Feature Scaling · Stock et al. (2021), QUA³CK · Daten: Kaggle „US Stocks & ETFs“ (Marjanovic), CCO