




WealthScope AI

ML-gestützte Finanzanalyse · QUA³CK-Prozessmodell

Data Analytics und Big Data (DSDABD072501) · Tutor: Klaus Quibeldey-Cirkel · Soufiane Fedan · Matrikelnr. 10247259

Leitfrage: Wie lassen sich historische US-Aktienmarktdaten nutzen, um mit Machine Learning eine interaktive Finanzanalyse-App zu bauen, die technische Analyse, ML-Signal und Risikoplanung nachvollziehbar verbindet — und ehrlich über ihre Grenzen ist?

DER WISSENSCHAFTLICHE FAHRPLAN



192.119

Datenpunkte

26

Blue-Chip-Ticker

55,3 %

Test-Accuracy

0,588

ROC-AUC ★

KERNANALYSEN (ML-INSIGHTS)

Pearson-Korrelationsmatrix — ML-Features




Abb. 1: Pearson-Korrelation der Features

Konfusionsmatrix (Test-Set, normalisiert je Zeile)




Abb. 2: Konfusionsmatrix (Test-Set)

Lernkurve — roc_auc vs. Trainingsgröße (5-Fold CV)




Abb. 3: Lernkurve (ROC-AUC vs. Trainingsgröße, 5-Fold CV) — Quelle: eigene Berechnung

Warum 55,3 % kein schlechtes Ergebnis sind. Nach der Efficient Market Hypothesis (Fama 1970) ist bei rein historischen Kursdaten eine Präzision knapp über 50 % das wissenschaftlich Erwartete. Ein Modell mit 55,3 %, das seine Grenzen kennt und erklärt (SHAP, Lernkurve), ist wertvoller als ein undurchsichtiges mit 95 %.

Methodik

RandomForest (Pipeline: Impute → Scale → RF), 5-Fold Stratified CV, StandardScaler nur auf Trainingsdaten (kein Data Leakage). 8 Features aus OHLCV, Ziel target_20d (Kurs in 20 Tagen höher?).

Grenzen (ehrlich benannt)

- Keine exogenen Faktoren (Makro, Geopolitik)
- Kein Sentiment im Modell
- Statisches Modell ohne Nachtraining
- Historie garantiert keine Zukunft

QUELLEN (KURZ)

Géron (2023), Praxiseinstieg ML (Kurslehrbuch, Kap. 1–9) · Fama (1970), Efficient Capital Markets · Lundberg & Lee (2017), SHAP · Li et al. (2024), Imputation · Pinheiro et al. (2025), Feature Scaling · Stock et al. (2021), QUA³CK · Daten: Kaggle „US Stocks & ETFs“ (Marjanovic), CCO